

# Automated Neural Architecture Search via Hybrid PSO-AFSA with OACE-Driven Performance Balancing for CIFAR-10

Lyanh Lopes Pinto<sup>1</sup>, Flávio Trindade Moura<sup>1</sup>, Jean Monteiro Pereira<sup>1</sup>,  
Jefferson Magalhães de Moraes<sup>1</sup>, Diego Lisboa Cardoso<sup>1</sup>, Glaucogoncalves<sup>1</sup>,  
Marcos César da Rocha Seruffo<sup>1</sup>

<sup>1</sup>Instituto de Tecnologia (ITEC) – Universidade Federal do Pará (UFPA)  
Belém – PA – Brasil

{lyanh.pinto, flavio.moura, jean.pereira}@itec.ufpa.br,

{jmoraes, diego, glaucogoncalves, seruffo}@ufpa.br

## Abstract.

**Resumo.** Este trabalho aborda o desafio da Busca de Arquitetura Neural (NAS) de otimizar simultaneamente a assertividade preditiva e o custo computacional, um fator frequentemente negligenciado, mas crítico para a implantação prática de modelos. Propõe-se um framework de NAS multi-objetivo que visa identificar arquiteturas com um balanço otimizado entre esses dois critérios conflitantes. A metodologia é estruturada em duas fases: primeiramente, um algoritmo híbrido que integra Particle Swarm Optimization (PSO) e posteriormente, o Artificial Fish Swarm Algorithm (AFSA) é empregado para gerar um conjunto diversificado de arquiteturas candidatas. Subsequentemente, o método OACE (Optimized Assertiveness-Cost Evaluation), uma abordagem de Tomada de Decisão com Múltiplos Critérios (MCDM), é utilizado para a seleção final, avaliando os modelos com base em um score que pondera explicitamente métricas de desempenho e custo. A validação empírica é conduzida na tarefa de classificação de imagens com o dataset CIFAR-10, com o objetivo de demonstrar sua capacidade de descobrir arquiteturas de Redes Neurais Convolucionais (CNNs) que sejam não apenas eficazes, mas também computacionalmente eficientes.

## 1. Introdução

O *Deep Learning* (DL) tem sido o principal motor de avanços em tarefas complexas de visão computacional, devida à capacidade de aprender representações hierárquicas diretamente de dados brutos [LeCun et al. 2015, LeCun et al. 1998a]. Entre suas diversas vertentes, as Redes Neurais Convolucionais (CNNs) destacam-se por alcançarem resultados de ponta em classificação de imagens, desde as arquiteturas com conexões residuais de [He et al. 2016] até os blocos multi-escala da família Inception de Szegedy *et al.* [Szegedy et al. 2015]. Nesse contexto, o design da arquitetura de uma CNN, que envolve decisões de profundidade, largura, tipos de convoluções, funções de ativação e padrões de conectividade — é fundamental, pois impacta diretamente a capacidade de generalização, a eficiência computacional e o desempenho global do modelo [Elsken et al. 2019].

O design manual de arquiteturas de DL demanda profundo conhecimento, intuição e longos ciclos de experimentação, consumindo recursos humanos e computacionais significativos [Elsken et al. 2019]. A *Neural Architecture Search* (NAS) surgiu para automatizar e otimizar esse processo [Zoph and Le 2017], mas enfrenta desafios notáveis, como o

espaço de busca exponencial de configurações e o alto custo para treinar e avaliar cada arquitetura candidata [Elsken et al. 2019]. Com base nisso, o NAS foi abordado de diversas maneiras, incluindo aprendizado por reforço [Zoph and Le 2017], algoritmos evolutivos [Real et al. 2019] e métodos baseados em gradiente [Liu et al. 2019]. Meta-heurísticas como *Particle Swarm Optimization* (PSO) [Kennedy and Eberhart 1995] e *Artificial Fish Swarm Algorithm* (AFSA) [Li et al. 2010] têm sido amplamente exploradas, mostrando-se promissoras, ainda mais quando combinadas para aprimoramento da convergência.

O problema central deste trabalho é a necessidade de desenvolver um método de NAS que vá além da otimização uni-objetivo, focada apenas na maximização da acurácia preditiva [Wu et al. 2019, Liu et al. 2023]. O objetivo é criar um *framework* capaz de identificar arquiteturas de redes neurais que não apenas apresentem alta assertividade, mas que também considerem explicitamente o custo computacional, resultando em modelos eficazes e eficientes para implementação no mundo real em ambientes com restrição de recursos [Li et al. 2023]. O desafio principal é como realizar essa busca multi-objetivo de forma eficaz em um vasto espaço de possibilidades e, posteriormente, como selecionar a arquitetura final de maneira equilibrada e fundamentada, levando em conta tanto a assertividade quanto o custo computacional [Deb et al. 2002].

Propomos um *framework* de NAS em duas etapas para abordar esse desafio. Na primeira etapa, utilizamos um algoritmo híbrido que combina duas meta-heurísticas: PSO e AFSA. Essa combinação visa gerar um conjunto diversificado de arquiteturas, explorando variações de parâmetros estruturais e hiperparâmetros essenciais. Na segunda etapa, aplicamos o método *Optimized Assertiveness-Cost Evaluation* (OACE) para a seleção final. Desenvolvido pelos autores em [Pinto et al. 2024], o método é validado neste estudo como uma evolução da proposta anterior, incorporando uma modelagem multicritério a um cenário de otimização com meta-heurísticas. A abordagem busca superar limitações e consolidar o OACE como um motor de otimização aprimorado. O método integra métricas de assertividade e custo de forma sistemática, oferecendo um ranqueamento objetivo dos modelos com base nos critérios do avaliador.

A validação empírica da metodologia será realizada com o *dataset* CIFAR-10 [Krizhevsky 2009], amplamente utilizado como benchmark em tarefas de classificação de imagens. Os objetivos principais deste trabalho são: 1) Desenvolver um algoritmo híbrido de NAS (AFSA-PSO) para explorar o espaço de arquiteturas; 2) Integrar o OACE para selecionar a arquitetura final, otimizando o *trade-off* entre assertividade e custo computacional; 3) Avaliar a eficácia do *framework* usando o CIFAR-10, comparando com arquiteturas de referência e abordagens alternativas; 4) Analisar o impacto das meta-heurísticas PSO e AFSA na qualidade das arquiteturas e na avaliação feita pelo OACE. Como contribuições, temos: 1) Uma nova abordagem híbrida de meta-heurísticas para NAS; 2) A validação do método OACE como critério de seleção final em um *pipeline* de NAS; 3) A proposição de um *framework* para a automatização e avaliação balanceada de arquiteturas de DL.

## 2. Referencial Teórico

As CNNs surgiram como uma extensão natural das Perceptrons Multicamadas, incorporando operações de convolução para aproveitar a estrutura espacial dos dados visuais. [LeCun et al. 1998b] demonstraram o potencial dessa arquitetura com o LeNet-5, obtendo alta acurácia em reconhecimento de dígitos manuscritos ao treinar redes profundas via

retropropagação. Esse trabalho iniciou a busca de arquiteturas cada vez mais profundas, mas foi somente com o advento do AlexNet que se evidenciou a importância de GPUs e regularização (*dropout*, *data augmentation*) para treinar redes com dezenas de camadas em conjuntos de imagens maiores [Krizhevsky et al. 2012].

À medida que a profundidade das redes aumentava, surgiam dificuldades de otimização e degradação de performance. [He et al. 2016] resolveram esse problema ao introduzir conexões residuais, que permitem o fluxo direto de gradientes através de atalhos (*skip connections*), viabilizando o treinamento de centenas de camadas sem perda de acurácia. Essa inovação levou ao desenvolvimento de variantes como ResNeXt e DenseNet, que exploram agrupamentos de caminhos paralelos e conexões densas para melhorar a reutilização de características internas. Em cenários de dispositivos embarcados, arquiteturas leves como MobileNetV2 [Sandler et al. 2018], que utiliza convoluções separáveis em profundidade, e ShuffleNet [Zhang et al. 2018], que adiciona roteamento de canais por *shuffle*, demonstraram excelente *trade-off* entre latência e acurácia.

O NAS propõe automatizar a descoberta de arquiteturas, definindo três componentes principais: *search space* (conjunto de camadas e conexões), *search strategy* (algoritmo para explorar o espaço) e *performance estimation* (método para avaliar cada candidato). O NAS automatiza a descoberta de arquiteturas definindo espaço de busca, estratégia e avaliação. Embora [Zoph and Le 2017] tenham inovado com aprendizado por reforço, o custo proibitivo de treinar candidatos do zero impulsionou métodos mais eficientes. Para contornar isso, surgiram abordagens como o ENAS (*one-shot* com compartilhamento de parâmetros) [Pham et al. 2018] e o DARTS (otimização em espaço contínuo via gradiente) [Liu et al. 2019], reduzindo drasticamente o tempo de busca.

Esses métodos diminuíram em ordens de magnitude o tempo de busca, mas ainda podem ficar presos em mínimos locais ou gerar arquiteturas pouco variadas. Outra vertente utiliza algoritmos inspirados em processos naturais. No âmbito das meta-heurísticas, o PSO explora o espaço via partículas que atualizam posições conforme melhores soluções globais e locais [Kennedy and Eberhart 1995]. O AFSA imita comportamentos cooperativos de peixes, alternando modos de busca exploratória e intensiva [Li et al. 2010]. Para problemas multi-objetivo (acurácia *versus* custo), NSGA-II fornece uma abordagem eficiente para obter uma frente de Pareto diversificada [Deb et al. 2002].

Nos últimos anos, pesquisas têm focado em sinergias entre meta-heurísticas e avaliação multi-objetivo. [Li et al. 2023] publicaram um *survey* sobre NAS evolutivo, destacando técnicas de reuso de pesos e subdivisão de busca para acelerar a otimização. Eles propuseram um framework que impõe restrições de recurso computacional via funções de custo customizadas. [Huang et al. 2023, Huang et al. 2024] aplicaram PSO para descobrir arquiteturas compactas e estenderam o método com herança hierárquica de pesos, melhorando a convergência. [Sinha et al. 2024] introduziram métricas de similaridade de representações para guiar a evolução, tornando o NAS sensível a características de hardware e latência. Além disso, Deng *et al.* exploraram NAS especializado em tarefas específicas, como reconhecimento de expressões faciais, validando a versatilidade dessas técnicas em domínios distintos [Deng et al. 2023].

Pinto *et al.* apresentaram o OACE, um método para avaliação de desempenho de modelos de ML que integra, de forma sistemática métricas de assertividade e custo com-

putacional [Pinto et al. 2024]. Em seu estudo de caso, aplicado à classificação de formas tridimensionais, o OACE identificou de maneira consistente os modelos que maximizam a assertividade e minimizam os custos operacionais. Já Wei *et al.* propuseram um algoritmo AFSA-GA-PSO para otimização de *Deep Belief Networks* (DBN) na detecção de intrusões [Wei et al. 2019]. Nesse método, o AFSA gera a população inicial, o PSO refina as partículas explorando o espaço de arquitetura da DBN, e o GA aplica operadores genéticos para escapar de mínimos locais, resultando em 24,7% de redução no tempo de detecção e ganhos de acurácia entre 1,3% e 14,8% em comparação a abordagens isoladas.

Diante do exposto, os trabalhos exploraram desde arquiteturas de CNNs até métodos de NAS (*ENAS*, *DARTS*), bem como abordagens evolutivas, meta-heurísticas isoladas (PSO, GA, AFSA) e multi-objetivas (*NSGA-II*). Estudos recentes integraram essas meta-heurísticas em *frameworks* híbridos e propuseram métricas de avaliação multi-objetivo, mas frequentemente sem um critério de seleção unificado que equilibre de forma explícita assertividade e custo. Portanto, ainda há escassez de *frameworks* que integrem meta-heurísticas de forma coordenada em uma *pipeline* única de NAS, bem como de critérios de avaliação que ponderem métricas de desempenho e custo de modo transparente. Assim, o presente trabalho garante uma nova abordagem ao combinar as meta-heurísticas PSO e AFSA em um único *pipeline* NAS, e adotar o OACE como função de seleção multi-objetivo, garantindo um *trade-off* fundamentado entre assertividade e custo.

### 3. Metodologia

O processo metodológico é detalhado em cinco etapas, começando pela Subseção 3.1 formaliza o problema e estabelece o modelo matemático que guia o método OACE. A Subseção 3.2 define do método avaliativo OACE e o modela em um MCDM. A Subseção 3.3 descreve o algoritmo híbrido AFSA-PSO desenvolvido para explorar o espaço de design e gerar arquiteturas candidatas. Subsequentemente, a Seção 3.4 explica a geração, o treinamento e a avaliação dos candidatos até a seleção do melhor modelo.

#### 3.1. Definição do Problema

Desenvolver modelos de ML que funcione eficazmente em ambientes com recursos limitados e que seja tanto assertivo quanto pouco custoso é um desafio significativo [Liu et al. 2024]. O problema se apresenta ao tentar balancear essas métricas ao passo de maximizar a confiabilidade ao mesmo tempo que minimize o custo dos modelos em aspectos avaliativos. Neste sentido, adota-se a formulação matemática descrita inicialmente por [Pinto et al. 2024], apresentada na Equação 1 e validada neste trabalho.

A modelagem matemática do método é centrada em uma função de otimização  $S_{\phi}(m)$ , que opera sobre dois componentes de suporte: a função de assertividade  $A(m)$  e a de custo  $C(m)$ , cada qual com suas respectivas restrições. A concepção de ambos os componentes se fundamenta nos princípios do *Weighted Sum Model* (WSM), uma técnica de MCDM que consolida múltiplos critérios em um *score* singular através de uma soma ponderada [Fishburn 1967].

$$\begin{aligned}
\max_m \quad & : S_\phi(m) = \lambda \cdot A(m) + (1 - \lambda) \cdot C(m) \\
\text{subject to} \quad & : A(m) = \sum_i w_a^i \cdot a_i(m) \\
& C(m) = - \sum_j w_c^j \cdot c_j(m) \\
& m \in M, \text{ (models set)} \\
& 0.5 \leq \lambda \leq 1 \\
& 0 \leq w_a^i, w_c^j \leq 1, \forall i, j \in \mathbb{N}
\end{aligned} \tag{1}$$

A assertividade, denotado por  $A(m)$ , é projetado para quantificar o desempenho preditivo agregado de um modelo. Tal quantificação é realizada pela soma de suas métricas de performance  $a_i(m)$ , as quais são previamente normalizadas e ponderadas por seus pesos de importância  $w_a^i$ . De forma análoga, o componente de custo  $C(m)$ , mensura o consumo de recursos computacionais do modelo, também por meio da agregação ponderada de suas métricas de custo normalizadas,  $c_j(m)$ , com seus respectivos pesos  $w_c^j$ .

A expressão central do método,  $S_\phi(m)$ , emerge da combinação desses dois componentes, produzindo a pontuação final que qualifica o modelo. A relevância de cada componente é calibrada pela variável  $\lambda$ , um parâmetro ajustável no intervalo  $[0, 1]$ . Quando  $\lambda$  se aproxima de 1, a avaliação privilegia a assertividade,  $A(m)$ . Em contrapartida, quando  $\lambda$  tende a 0.5, a prioridade recai sobre o baixo custo, representado por  $C(m)$ .

### 3.2. Método Avaliativo OACE

O OACE é um método projetado especificamente para o desafio de selecionar a arquitetura de rede neural mais adequada sob a influência de critérios conflitantes: assertividade preditiva e custo computacional. Esse processo é realizado aplicando a formulação 1 (Subseção 3.1) sobre uma modelagem MCDM, permitindo transformar um processo de escolha, muitas vezes subjetivo e complexo, em uma avaliação estruturada, transparente e matematicamente fundamentada.

De acordo com as diretrizes de [Yang 2020], um problema de MCDM, no contexto do OACE, é definido por quatro componentes principais. Primeiramente, as alternativas correspondem ao conjunto de modelos ou arquiteturas de rede neural candidatas,  $M = \{m_1, m_2, \dots, m_n\}$ , que foram geradas durante a fase de busca e precisam ser avaliadas e ranqueadas. Em segundo lugar, os critérios,  $N = \{a_1, \dots, a_p, c_1, \dots, c_q\}$ , são as métricas de desempenho utilizadas para julgar as alternativas, divididos em dois critérios distintos: assertividade ( $a_k$ ), que quantificam a capacidade do modelo de realizar previsões corretas, e de custo ( $c_l$ ), que mensuram os recursos computacionais consumidos pelo modelo.

A importância relativa de cada critério é quantificada por um conjunto de pesos  $w = \{w_1^a, \dots, w_p^a, w_1^c, \dots, w_q^c\}$ , os quais, para garantir objetividade, são determinados sistematicamente através do *Analytic Hierarchy Process* (AHP), um método MCDM que decompõe o problema em uma hierarquia e deriva os pesos a partir de comparações paritárias entre os critérios. Finalmente, a função de decisão é a própria função-objetivo  $S_\phi(m)$ , que agrega o desempenho de uma alternativa em todos os critérios, ponderados por seus respectivos pesos, para gerar um escore final que permite o ranqueamento.

A estrutura de agregação do OACE é fundamentada no WSM, onde as pontuações de assertividade,  $A(m)$ , e de custo,  $C(m)$ , são primeiramente calculadas e, em seguida, combinadas pela função  $S_\phi(m)$ . O parâmetro  $\lambda$  atua como um peso de alto nível, permitindo que o tomador de decisão (o pesquisador ou desenvolvedor) ajuste a prioridade entre os dois objetivos macro: maximizar a assertividade e minimizar o custo computacional. Essa flexibilidade, controlada por  $\lambda$ , torna o OACE uma potencial ferramenta flexível para otimizar a seleção de modelos em diferentes contextos de aplicação, desde ambientes com recursos restritos até cenários que demandam máxima performance.

### 3.3. Algoritmo Híbrido AFSA-PSO

O AFSA-PSO é uma meta-heurística híbrida projetada para otimizar a arquitetura de redes neurais, determinando a estrutura mais eficaz em termos de parâmetros estruturais e hiperparâmetros da rede. Proposto por [Wei et al. 2019], este método combina as capacidades exploratórias do AFSA que é enriquecido pela velocidade de convergência do PSO. No contexto deste estudo, o AFSA-PSO é adaptado para realizar uma NAS, onde a qualidade de cada arquitetura é avaliada pela função-objetivo  $S_\phi$  (Subseção 3.1).

O PSO é uma meta-heurística de inteligência de enxame que otimiza soluções simulando o comportamento social biológico, onde partículas ajustam suas trajetórias baseadas em experiências pessoais ( $p_{best}$ ) e globais ( $g_{best}$ ) [Kennedy and Eberhart 1995]. Para mitigar a convergência prematura típica deste método, a presente abordagem integra, de forma cíclica e contínua, mecanismos do AFSA [Wang et al. 2005]. Diferente de hibridizações que limitam o AFSA à inicialização, esta implementação submete as partículas a comportamentos de agrupamento, forrageamento e movimento aleatório em cada iteração, ampliando a capacidade de escape de ótimos locais.

O funcionamento do algoritmo ocorre em duas fases distintas dentro de cada ciclo geracional. Na primeira fase, a componente AFSA introduz perturbações estratégicas nas partículas baseadas em três comportamentos: aglomeração (*clustering*), forrageamento (*foraging*) e movimento aleatório. O comportamento de aglomeração avalia o centro de massa dos vizinhos dentro do campo visual da partícula; caso a aptidão desta região central seja superior à posição atual, a partícula move-se em sua direção. Se a aglomeração não for benéfica, aciona-se o forrageamento, que explora posições estocásticas dentro do raio visual em busca de melhorias de aptidão. Como mecanismo de última instância para evitar estagnação, aplica-se o movimento aleatório.

As formulações matemáticas que regem a magnitude e direção destes deslocamentos seguem estritamente as definições original dos algoritmo AFSA e PSO isoladas, apresentadas por [Wei et al. 2019], dispensando novas notações neste trabalho. Após a etapa de pré-otimização realizada pelo AFSA, inicia-se a fase de refinamento via PSO. Neste estágio, aplicam-se os operadores clássicos de inércia, aceleração cognitiva e aceleração social sobre as posições já modificadas, refinando a busca em direção ao melhor global ( $g_{best}$ ). Essa estrutura de decisão permite um equilíbrio dinâmico entre a exploração global e a convergência. A estrutura de execução detalhada é apresentada no Algoritmo 1.

### 3.4. Geração, Treinamento e Avaliação dos Candidatos

A culminação do processo de otimização arquitetural, conduzido pelo algoritmo AFSA-PSO, resulta na identificação de um conjunto de arquiteturas candidatas que demonstram elevado potencial segundo a função-objetivo  $S_\phi$ . A avaliação operada durante essa

---

**Algorithm 1:** Otimização de Arquitetura via AFSA-PSO

---

**Input:** População  $N$ , Iterações  $T_{max}$ , Parâmetros  $(w, c_1, c_2, V, S)$

**Output:** Melhor arquitetura  $g_{best}$

```
1 Inicializar população  $X$  e velocidades  $v$  aleatoriamente;
2 Avaliar aptidão inicial  $S_\phi(x_i)$  para toda partícula  $i \in N$ ;
3 Definir  $p_{best,i} \leftarrow x_i$  e identificar  $g_{best}$  inicial;
4 for  $t \leftarrow 1$  to  $T_{max}$  do
5     foreach partícula  $i \in N$  do
6         Calcular centro da vizinhança  $x_c$  (com raio  $< V$ );
7         if  $S_\phi(x_c) > S_\phi(x_i)$  then
8             | Atualizar  $x_i$  via Aglomeração;
9         else
10            Gerar ponto exploratório  $x_{exp}$  (com raio  $V$ );
11            if  $S_\phi(x_{exp}) > S_\phi(x_i)$  then
12                | Atualizar  $x_i$  via Forrageamento;
13            else
14                | Atualizar  $x_i$  via Movimento Aleatório;

15     foreach partícula  $i \in N$  do
16         Atualizar velocidade  $v_i$  (Inércia + Cognitivo + Social);
17         Atualizar posição final:  $x_i \leftarrow x_i + v_i$ ;
18          $fitness \leftarrow S_\phi(x_i)$ ;
19         if  $fitness > S_\phi(p_{best,i})$  then
20             |  $p_{best,i} \leftarrow x_i$ ;
21             if  $fitness > S_\phi(g_{best})$  then
22                 |  $g_{best} \leftarrow x_i$ ;

23 return  $g_{best}$ ;
```

---

operação é realizada a partir da função objetivo  $S_\phi(m)$ , que integra critérios de assertividade e custo (Subseção 3.2). A atribuição dos pesos para cada conjunto de métricas (ou critérios) dentro das funções de assertividade  $A(m)$  e custo  $C(m)$  são sistematicamente determinadas através do AHP.

Proposto por Saaty (1977) [Saaty 1977], o AHP é um MCDM que decompõe um problema em uma hierarquia de critérios, permitindo a obtenção de pesos que facilita a tomada de decisão. A importância das métricas é definida a partir dos critérios do desenvolvedor. Entre os passos da implementação de Saaty (1977) [Saaty 1977], destaca-se, nesse processo, a construção da matriz de critérios pela comparação par a par entre as métricas selecionadas. Como resultado, os pesos  $w_i^a$  e  $w_j^c$  são obtidos, possibilitando uma análise objetiva das métricas nas etapas subsequentes de cálculo das funções do método OACE.

## **4. Experimento**

### **4.1. Conjunto de Dados**

### **4.2. Seleção das Arquiteturas**

### **4.3. Parametrização do Algoritmo Híbrido**

### **4.4. Parametrização do Método Avaliativo**

### **4.5. Avaliação de Performance**

## **5. Resultados e Discussão**

## **6. Conclusão**

## **Referências**

- Deb, K., Pratap, A., Agarwal, S., and Meyarivan, T. (2002). A fast and elitist multiobjective genetic algorithm: Nsga-ii. *IEEE Transactions on Evolutionary Computation*, 6(2):182–197.
- Deng, S., Lv, Z., Galván, E., and Sun, Y. (2023). Evolutionary neural architecture search for facial expression recognition. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 7(5):1405–1419.
- Elsken, T., Metzen, J. H., and Hutter, F. (2019). Neural architecture search: A survey. *Journal of Machine Learning Research*, 20:1–21.
- Fishburn, P. C. (1967). Letter to the editor—additive utilities with incomplete product sets: Application to priorities and assignments. *Operations Research*, 15(3):537–542.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778. IEEE.
- Huang, J., Xue, B., Sun, Y., Zhang, M., and Yen, G. G. (2023). Particle swarm optimization for compact neural architecture search for image classification. *IEEE Transactions on Evolutionary Computation*, 27(5):1298–1312.
- Huang, J., Xue, B., Sun, Y., Zhang, M., and Yen, G. G. (2024). Split-level evolutionary neural architecture search with elite weight inheritance. *IEEE Transactions on Neural Networks and Learning Systems*, 35(10):13523–13537.

- Kennedy, J. and Eberhart, R. (1995). Particle swarm optimization. In *Proceedings of the IEEE International Conference on Neural Networks*, volume 4, pages 1942–1948.
- Krizhevsky, A. (2009). Learning multiple layers of features from tiny images. Technical report tr-2009-67, Department of Computer Science, University of Toronto. Dataset disponível em <https://www.cs.toronto.edu/~kriz/cifar.html>.
- Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems*, volume 25, pages 1097–1105. NeurIPS.
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature*, 521(7553):436–444.
- LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998a). Gradient-based learning applied to document recognition. In *Proceedings of the IEEE*, volume 86, pages 2278–2324. IEEE.
- LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998b). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324.
- Li, S., Sun, Y., and Yen, G. G. (2023). Automatic design of convolutional neural network architectures under resource constraints. *IEEE Transactions on Neural Networks and Learning Systems*, 34(8):3832–3846.
- Li, X., Hu, Y., and Liu, Z. (2010). Artificial fish swarm algorithm for optimization. In *2010 International Conference on Machine Learning and Cybernetics*, volume 4, pages 1524–1539. IEEE.
- Liu, H., Simonyan, K., and Yang, Y. (2019). Darts: Differentiable architecture search. In *International Conference on Learning Representations*.
- Liu, H.-I., Galindo, M., Xie, H., Wong, L.-K., Shuai, H.-H., Li, Y.-H., and Cheng, W.-H. (2024). Lightweight deep learning for resource-constrained environments: A survey. *ACM Computing Surveys*.
- Liu, Y., Sun, Y., Xue, B., Zhang, M., Yen, G. G., and Tan, K. C. (2023). A survey on evolutionary neural architecture search. *IEEE Transactions on Neural Networks and Learning Systems*, 34(2):550–570.
- Pham, H., Guan, M. Y., Zoph, B., Le, Q. V., and Dean, J. (2018). Efficient neural architecture search via parameter sharing. In *International Conference on Machine Learning*, pages 4092–4101.
- Pinto, L. V. L., Alves, A. V. N., Dos Santos, A. M., Moura, F. R. T., Oliveira, W. D. S., de Moraes, J. M., de Oliveira, R. L., Cardoso, D. L., and Seruffo, M. C. D. R. (2024). Optimized assertiveness-cost evaluation: An innovative performance measuring method for machine learning models. In *2024 IEEE Latin American Conference on Computational Intelligence (LA-CCI)*, pages 1–6. IEEE.
- Real, E., Aggarwal, A., Huang, Y., and Le, Q. V. (2019). Regularized evolution for image classifier architecture search. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 4780–4789.
- Saaty, T. L. (1977). A scaling method for priorities in hierarchical structures. *Journal of mathematical psychology*, 15(3):234–281.

- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., and Chen, L.-C. (2018). Mobilenetv2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4510–4520. IEEE.
- Sinha, N., Shabayek, A. E. R., Kacem, A., Rostami, P., Schneider, C., and Aouada, D. (2024). Hardware aware evolutionary neural architecture search using representation similarity metric. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 2616–2625.
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., and Rabinovich, A. (2015). Going deeper with convolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 1–9. IEEE.
- Wang, C.-R., Zhou, C.-L., and Ma, J.-W. (2005). An improved artificial fish-swarm algorithm and its application in feed-forward neural networks. In *2005 International conference on machine learning and cybernetics*, volume 5, pages 2890–2894. IEEE.
- Wei, P., Li, Y., Zhang, Z., Hu, T., Li, Z., and Liu, D. (2019). An optimization method for intrusion detection classification model based on deep belief network. *IEEE Access*, 7:87593–87605.
- Wu, B., Dai, X., Zhang, P., Wang, Y., and Sun, F. (2019). Fbnet: Hardware-aware efficient convnet design via differentiable neural architecture search. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 10746–10755. IEEE.
- Yang, X.-S. (2020). *Nature-inspired optimization algorithms*. Academic Press.
- Zhang, X., Zhou, X., Lin, M., and Sun, J. (2018). Shufflenet: An extremely efficient convolutional neural network for mobile devices. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 684–699. Springer.
- Zoph, B. and Le, Q. V. (2017). Neural architecture search with reinforcement learning. In *International Conference on Learning Representations*.